

Лабораторная работа 4

Работу выполнили:

Шубин Егор

Санатин Дмитрий

Преподаватель:

Танченко Юлия Валерьевна

Условие

Дана выборка пар (x_i, t_i) , $i = 1, \dots, n$, где $n = 20$. Требуется методом наименьших квадратов найти коэффициенты регрессионной модели

$$f(x) = w_0 + w_1x + w_2x^2,$$

а также вычислить среднеквадратическое отклонение

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (t_i - f(x_i))^2}.$$

На графике необходимо изобразить исходные точки выборки (x_i, t_i) и график полученной регрессии.

Несмотря на то, что в условии используется формулировка “линейная регрессия”, модель является квадратичной по переменной x . При этом она остается линейной по неизвестным параметрам w_0, w_1, w_2 , поэтому коэффициенты можно находить стандартным методом наименьших квадратов через систему нормальных уравнений.

Исходные данные

i	1	2	3	4	5	6	7	8	9	10
x_i	1.0	1.1	1.2	1.3	1.4	1.5	1.6	1.7	1.8	1.9
t_i	2.0	1.9	1.7	1.6	1.3	1.1	1.3	1.2	1.1	1.0
i	11	12	13	14	15	16	17	18	19	20
x_i	2.0	2.1	2.2	2.3	2.4	2.5	2.6	2.7	2.8	2.9
t_i	0.8	1.1	0.9	1.2	1.2	1.2	1.4	1.5	1.5	1.7

Метод наименьших квадратов

Ищем такие коэффициенты w_0, w_1, w_2 , при которых сумма квадратов ошибок минимальна:

$$S(w_0, w_1, w_2) = \sum_{i=1}^n (t_i - w_0 - w_1x_i - w_2x_i^2)^2 \rightarrow \min.$$

В матричной форме задача записывается через матрицу признаков

$$X = \begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix}, \quad w = \begin{pmatrix} w_0 \\ w_1 \\ w_2 \end{pmatrix}, \quad t = \begin{pmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{pmatrix}.$$

Тогда вектор предсказаний равен Xw , а минимизируемая величина принимает вид

$$S(w) = \|t - Xw\|^2.$$

Условие минимума для квадратичной функции приводит к нормальным уравнениям:

$$X^T X w = X^T t.$$

Расчет нормальных уравнений

Для модели $f(x) = w_0 + w_1 x + w_2 x^2$ система нормальных уравнений имеет вид

$$\begin{pmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{pmatrix} \begin{pmatrix} w_0 \\ w_1 \\ w_2 \end{pmatrix} = \begin{pmatrix} \sum t_i \\ \sum x_i t_i \\ \sum x_i^2 t_i \end{pmatrix}.$$

По исходной выборке получаем следующие суммы:

$$\begin{aligned} n &= 20, & \sum x_i &= 39.0000, & \sum x_i^2 &= 82.7000, \\ \sum x_i^3 &= 187.2000, & \sum x_i^4 &= 444.8666, & \sum t_i &= 26.7000, \\ \sum x_i t_i &= 51.0300, & \sum x_i^2 t_i &= 108.0670. \end{aligned}$$

Следовательно,

$$\begin{pmatrix} 20 & 39.0000 & 82.7000 \\ 39.0000 & 82.7000 & 187.2000 \\ 82.7000 & 187.2000 & 444.8666 \end{pmatrix} \begin{pmatrix} w_0 \\ w_1 \\ w_2 \end{pmatrix} = \begin{pmatrix} 26.7000 \\ 51.0300 \\ 108.0670 \end{pmatrix}.$$

Решая данную систему, получаем:

$$\boxed{w_0 = 4.996625, \quad w_1 = -3.929904, \quad w_2 = 0.967760}.$$

Итоговая регрессионная зависимость:

$$\boxed{f(x) = 4.996625 - 3.929904x + 0.967760x^2}.$$

Проверка по точкам выборки

i	x_i	t_i	$f(x_i)$	$t_i - f(x_i)$
1	1.0	2.0	2.034481	-0.034481
2	1.1	1.9	1.844720	0.055280
3	1.2	1.7	1.674314	0.025686
4	1.3	1.6	1.523264	0.076736
5	1.4	1.3	1.391569	-0.091569
6	1.5	1.1	1.279229	-0.179229
7	1.6	1.3	1.186244	0.113756
8	1.7	1.2	1.112614	0.087386
9	1.8	1.1	1.058340	0.041660
10	1.9	1.0	1.023421	-0.023421
11	2.0	0.8	1.007857	-0.207857
12	2.1	1.1	1.011648	0.088352
13	2.2	0.9	1.034795	-0.134795
14	2.3	1.2	1.077297	0.122703
15	2.4	1.2	1.139154	0.060846
16	2.5	1.2	1.220366	-0.020366
17	2.6	1.4	1.320933	0.079067
18	2.7	1.5	1.440856	0.059144
19	2.8	1.5	1.580133	-0.080133
20	2.9	1.7	1.738766	-0.038766

Вычисление RMSE

Сумма квадратов остатков равна

$$\sum_{i=1}^{20} (t_i - f(x_i))^2 = 0.180189.$$

Тогда средний квадрат ошибки:

$$MSE = \frac{1}{20} \cdot 0.180189 = 0.009009.$$

Отсюда

$$RMSE = \sqrt{0.009009} = 0.094918.$$

Полученное значение RMSE меньше 0.1, то есть типичное отклонение модели от наблюдаемых значений составляет примерно 0.095 единицы по оси t .

Дополнительная оценка качества

Для интерпретации результата полезно также вычислить общую сумму квадратов отклонений наблюдений от среднего значения:

$$SST = \sum_{i=1}^{20} (t_i - \bar{t})^2, \quad \bar{t} = \frac{1}{20} \sum_{i=1}^{20} t_i = 1.335.$$

По данным выборки

$$SST = 1.985500.$$

Коэффициент детерминации равен

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{0.180189}{1.985500} = 0.909248.$$

Следовательно, построенная квадратичная модель объясняет примерно 90.9% разброса значений t_i относительно их среднего значения.

Так как $w_2 > 0$, парабола направлена ветвями вверх. Ее вершина находится в точке

$$x_* = -\frac{w_1}{2w_2} = 2.030412, \quad f(x_*) = 1.006962.$$

Это согласуется с таблицей исходных данных: минимальные наблюдаемые значения расположены около $x = 2.0$.

График регрессии




Рис. 1: Исходные точки и найденная квадратичная регрессия.

График остатков

Остатки $e_i = t_i - f(x_i)$ показывают, насколько сильно каждое наблюдение отклоняется от найденной регрессионной кривой. Для хорошей аппроксимации они должны быть небольшими и не образовывать выраженной систематической структуры.




Рис. 2: Остатки регрессии для каждой точки выборки.

Вывод

Методом наименьших квадратов была построена квадратичная регрессионная модель

$$f(x) = 4.996625 - 3.929904x + 0.967760x^2.$$

Она отражает U-образную зависимость в данных: значения t сначала убывают при росте x , достигают минимума около середины рассматриваемого интервала, а затем начинают возрастать. Среднеквадратическое отклонение модели от выборки равно

$$RMSE = 0.094918.$$

Коэффициент детерминации $R^2 = 0.909248$ показывает, что модель объясняет большую часть изменчивости исходных наблюдений. График остатков подтверждает, что ошибки аппроксимации невелики: максимальные по модулю отклонения находятся около 0.2, а типичная ошибка составляет около 0.095. Таким образом, полученная регрессия достаточно точно описывает заданные точки.